

Frameworks y regulaciones de IA

Versión ampliada con clasificación de instrumentos: hard law, soft law y declaraciones internacionales

Ética, riesgos, gobernanza, cumplimiento y cooperación internacional · 2026

Tres categorías para leer el ecosistema de IA

No todos los instrumentos obligan de la misma manera ni sirven para lo mismo

Hard law

Normas vinculantes: reglamentos, directivas, leyes o tratados. Definen obligaciones exigibles, responsabilidades, sanciones y mecanismos de cumplimiento.

Soft law ético-regulatorio

Principios, guías, estándares, marcos de gestión y listas de evaluación. No siempre son obligatorios, pero orientan buenas prácticas y auditorías.

Declaraciones y cooperación

Consensos político-diplomáticos, redes y agendas internacionales. No imponen obligaciones directas, pero coordinan prioridades, capacidades y convergencia.

Cómo decidir dónde ubicar un instrumento

Criterios simples para una lectura jurídica, ética y técnica

Criterio	Hard law	Soft law	Declaración / cooperación
Efecto	Obligatorio y exigible	Orientador, técnico o interpretativo	Político, diplomático o institucional
Ejemplos	AI Act, GDPR, Convenio del Consejo de Europa	UNESCO, OECD, NIST AI RMF, ISO/IEC 42001	París 2025, Singapore Consensus, ASEAN AI SAFE, New Delhi 2026
Pregunta clave	¿Qué debemos cumplir?	¿Cómo demostramos buena gobernanza?	¿Qué agenda o consenso internacional orienta la acción?
Uso en proyecto	Cumplimiento, contratos, auditoría legal	Gestión de riesgos, métricas, documentación	Cooperación, capacidades, investigación y políticas públicas

Fuente: síntesis elaborada a partir del DOCX del usuario.



1

Hard law jurídicamente vinculante

Obligaciones, derechos, controles y sanciones

Instrumentos de hard law incluidos

La capa obligatoria del ecosistema regulatorio

Reglamento (UE) 2024/1689 – AI Act: régimen armonizado de IA con enfoque basado en riesgos.

Consejo de Europa: Framework Convention on AI, Human Rights, Democracy and the Rule of Law.

Reglamento (UE) 2016/679 – GDPR: datos personales, bases legales y decisiones automatizadas.

Directiva (UE) 2016/680 – Law Enforcement Directive: tratamiento de datos en materia penal y seguridad.

Brasil: Marco Civil, LGPD, ANPD, Estatuto Digital de la Niñez y Ley de Gobierno Digital como hard law regional.

AI Act de la Unión Europea

Marco integral con enfoque por niveles de riesgo

Qué regula

- Prácticas prohibidas de riesgo inaceptable.
- Sistemas de alto riesgo con requisitos de gobernanza, documentación y monitoreo.
- Obligaciones de transparencia para ciertos sistemas.
- Reglas específicas para modelos de propósito general.

Qué exige a un proyecto

- Clasificar el sistema por riesgo y uso previsto.
- Documentar datos, finalidad, pruebas y supervisión humana.
- Gestionar incidentes y monitoreo postdespliegue.
- Producir evidencia para auditoría y cumplimiento.

Convenio del Consejo de Europa + GDPR

Derechos humanos, democracia, Estado de derecho y protección de datos

Convenio de IA

- Tratado internacional jurídicamente vinculante.
- Centrado en derechos humanos, democracia y Estado de derecho.
- Relevante para compras públicas, servicios digitales y políticas institucionales.

GDPR y LED

- GDPR: datos personales, transparencia, minimización y decisiones automatizadas.
- LED: tratamiento por autoridades competentes en materia penal y seguridad.
- Ambos condicionan el diseño de sistemas de IA con datos personales.

Brasil: hard law sobre datos e internet

Ubicar el caso brasileño dentro de la capa obligatoria, no solo como ejemplo regional

Marco Civil de Internet

- Ley 12.965/2014: principios, garantías, derechos y deberes para el uso de Internet.
- Base para neutralidad de red, privacidad, libertad de expresión y responsabilidades de intermediarios.
- Decreto 8.771/2016 reglamenta neutralidad y protección de registros/datos; modificado en 2026.

LGPD + ANPD

- Ley 13.709/2018: régimen general de protección de datos personales.
- Principios: finalidad, necesidad, transparencia, seguridad, prevención y no discriminación.
- Ley 14.460/2022 transforma la ANPD en autarquía de naturaleza especial.

Infancia y servicios públicos

- Ley 15.211/2025: Estatuto Digital de la Niñez y Adolescencia para protección en ambientes digitales.
- Decretos 12.622/2025 y 12.880/2026 reglamentan autoridad y política de protección digital infantil.
- Ley 14.129/2021: principios y reglas para Gobierno Digital y servicios públicos.

Brasil: obligaciones para IA y plataformas

Brasil permite analizar obligaciones concretas antes de entrenar, comprar o desplegar

Datos y decisiones automatizadas

- Identificar base legal, finalidad, datos necesarios, retención y seguridad.
- Revisar decisiones tomadas únicamente con tratamiento automatizado cuando afecten intereses del titular.

Plataformas y contenido

- Marco Civil articula libertad de expresión, privacidad, neutralidad y responsabilidad de intermediarios.
- La jurisprudencia y proyectos legislativos tensionan remoción, moderación, transparencia y garantías.

Menores y diseño persuasivo

- El Estatuto Digital de la Niñez y Adolescencia refuerza deberes de protección en ambientes digitales.
- Relevante para loot boxes, publicidad, perfilado, notificaciones, monetización y diseño adictivo.

Gobierno digital

- La Ley de Gobierno Digital conecta servicios digitales, transparencia, interoperabilidad y protección de datos.
- Permite discutir IA pública, trazabilidad, soberanía de datos y continuidad de servicios críticos.

Lectura para la PPTX: Brasil aporta hard law regional sobre datos, internet, menores y Estado digital; aún no equivale a un AI Act general.

Preguntas de cumplimiento para una IA institucional

Una guía breve antes de diseñar, comprar o desplegar

- ¿El sistema toma decisiones que afectan derechos, acceso a servicios, empleo, educación o beneficios?
- ¿Procesa datos personales, datos sensibles o datos de personas menores de edad?
- ¿Hay supervisión humana real, canales de apelación y explicación comprensible?
- ¿Existen registros, evaluación de impacto, gestión de incidentes y controles postdespliegue?

2

Soft law ético-regulatorio

Principios, estándares y marcos de gestión para operacionalizar la IA responsable

Instrumentos principales de soft law

Funcionan como guías normativas, referencias y marcos de evaluación

UNESCO Recommendation on the Ethics of AI; OECD AI Principles; Ethics Guidelines for Trustworthy AI y ALTAI.
NIST AI RMF 1.0; ISO/IEC 42001:2023; ISO/IEC 23894:2023; ISO/IEC 22989.
Blueprint for an AI Bill of Rights, OMB M-24-10, documentos de EEOC y FTC.
Documentos del EDPB y Recomendaciones para una Inteligencia Artificial Fiable de Argentina.
Brasil: EBIA, Plano Brasileiro de IA, guías ANPD, CGI.br y estrategias de gobierno digital.

UNESCO, OECD y Trustworthy AI

La base ética compartida: derechos, confianza y gobernanza

Principios recurrentes

- Derechos humanos, dignidad y no discriminación.
- Transparencia, explicabilidad y rendición de cuentas.
- Privacidad, seguridad, robustez y sostenibilidad.
- Participación, inclusión y diversidad contextual.

Uso práctico

- Diseñar checklists de impacto y riesgos.
- Definir criterios de aceptación para proyectos.
- Traducir valores a controles verificables.
- Formar estudiantes y equipos técnicos en ética aplicada.

NIST AI RMF e ISO/IEC

De los principios a un sistema de gestión

NIST AI RMF

- Funciones: Govern, Map, Measure, Manage.
- Enfoque flexible para identificar, medir y gestionar riesgos.
- Útil para matrices de riesgo, controles y documentación.

ISO/IEC

- ISO/IEC 42001: sistema de gestión de IA.
- ISO/IEC 23894: gestión de riesgos de IA.
- ISO/IEC 22989: conceptos y terminología.
- Aporta lenguaje común para auditorías y procesos.

Estados Unidos: guías y enforcement sectorial

No todo es ley general: también hay interpretación y aplicación por agencias

Instrumentos orientadores

- Blueprint for an AI Bill of Rights.
- OMB M-24-10 para uso de IA en agencias federales.
- NIST como referencia técnica para seguridad, confianza y evaluación.

Agencias con impacto

- EEOC: discriminación laboral y herramientas automatizadas.
- FTC: protección del consumidor, prácticas engañosas y claims sobre IA.
- La guía puede convertirse en criterio de supervisión o enforcement.

Estados Unidos 2026: nueva orden ejecutiva sobre IA avanzada

Promoting Advanced Artificial Intelligence Innovation and Security · 2 de junio de 2026

1 Orientación política

Busca combinar liderazgo estadounidense en IA, adopción rápida, seguridad nacional y ciberdefensa. No reemplaza marcos como NIST AI RMF: los complementa desde una lógica ejecutiva y de seguridad.

2 Ciberseguridad como eje

Ordena priorizar la defensa de sistemas federales y promover herramientas defensivas de IA. También prevé un clearinghouse para coordinar detección, validación y remediación de vulnerabilidades.


3 Lectura regulatoria

Encaja mejor como directiva ejecutiva y marco operativo de gobernanza: genera obligaciones internas para agencias, pero no crea una ley general de IA equivalente al AI Act europeo.

Fuente: White House, Executive Order “Promoting Advanced Artificial Intelligence Innovation and Security” (02/06/2026); AP News; WSJ.

Modelos frontera: revisión voluntaria antes del despliegue

La novedad práctica es el vínculo entre modelos avanzados, riesgo cibernético y acceso temprano del gobierno



Para la clasificación de la presentación: ubicarla entre soft law/gobernanza ejecutiva y política de seguridad nacional, no como hard law general.

Para proyectos universitarios: usarla como ejemplo de transición desde principios generales hacia controles operativos sobre modelos frontera y ciberseguridad.

Fuente: White House, Sec. 3 Secure Frontier Model Deployment, AP News (02/06/2026); WSJ.

Argentina: IA fiable y lineamientos nacionales

Ubicación sugerida dentro de la clasificación

- Cuando funcionan como recomendaciones, principios rectores o guías institucionales, se ubican en soft law.
- Son útiles para alinear proyectos públicos, docencia, investigación y transferencia con criterios de IA responsable.
- Pueden orientar compras, evaluación de impacto, trazabilidad, supervisión humana y documentación.
- Conviene diferenciarlas de regímenes obligatorios completos o sancionatorios.

Brasil: guías, estrategias y gobernanza

La capa orientativa complementa las leyes y ayuda a operacionalizar IA responsable

Estrategias públicas

- EBIA: estrategia nacional para promover IA con desarrollo científico, innovación y solución de problemas del país.
- Plano Brasileiro de IA: agenda de capacidades nacionales, infraestructura, investigación y uso público.
- Estrategias de Gobierno Digital 2024–2027: inclusión, eficacia, datos e interoperabilidad.

ANPD: orientación técnica

- Guías y documentos orientativos traducen la LGPD a criterios prácticos para agentes de tratamiento.
- Materiales sobre alto riesgo, decisiones automatizadas y tratamiento de datos en IA generativa.
- Sirven para auditorías, DPIA, documentación y criterios de aceptación institucional.

CGI.br y gobernanza

- Decálogo de principios de 2009: derechos humanos, privacidad, neutralidad, diversidad y gobernanza democrática.
- Principios para redes sociales: referencia multiactor para futuras obligaciones de plataformas.
- Aporta legitimidad y participación social, más allá del cumplimiento formal.

Brasil: clasificación hard law / soft law

Una lectura para integrar Brasil con AI Act, GDPR, NIST e ISO

Capa	Instrumentos brasileños	Uso en proyecto de IA
Hard law	Marco Civil; LGPD; Ley 14.460/ANPD; Ley 15.211/2025; Ley 14.129/2021	Cumplimiento jurídico: datos, derechos, menores, intermediarios, Estado digital y responsabilidades.
Soft law	EBIA; Plano Brasileiro de IA; guías ANPD; CGI.br; estrategias de gobierno digital	Gobernanza práctica: checklists, criterios de riesgo, auditoría, participación y capacidades nacionales.
En debate	PL 2630/2020; jurisprudencia sobre art. 19; regulación específica de plataformas	Seguimiento regulatorio: transparencia, moderación, publicidad, cuentas automatizadas y garantías.

Clave docente: Brasil muestra que la soberanía digital combina normas vinculantes, guías técnicas, infraestructura pública y gobernanza multiactor.

Fuente: síntesis docente basada en legislación brasileña, MCTI, Gov.br, ANPD y CGI.br.

Brasil: soberanía digital y gobernanza de IA

Un modelo latinoamericano que combina derechos, plataformas, datos e infraestructura pública

- • Marco Civil de Internet: principios, garantías, derechos y deberes para el uso de Internet.
- LGPD y ANPD: régimen general de protección de datos personales y autoridad regulatoria.
- Redes sociales y plataformas: responsabilidad, transparencia y moderación en debate legislativo y judicial.
- Nube de Gobierno: soberanía de datos y soberanía operativa para servicios públicos críticos.

Marco Civil + LGPD: derechos, neutralidad y datos personales

De la ciudadanía digital al tratamiento responsable de datos

- • Marco Civil: libertad de expresión, privacidad, protección de datos y neutralidad de la red.
- LGPD: finalidad, adecuación, necesidad, transparencia, seguridad, prevención y no discriminación.
- La protección de datos no depende solo del consentimiento: exige proporcionalidad, minimización y rendición de cuentas.
- La ANPD orienta, regula y fiscaliza el cumplimiento, clave para pasar de principios a enforcement.

Redes sociales, responsabilidad y protección de menores

El caso brasileño muestra una regulación en evolución y con fuerte intervención institucional

- • La responsabilidad de plataformas surge de Marco Civil, LGPD, legislación electoral, consumo, infancia y jurisprudencia.
- El debate sobre el artículo 19 del Marco Civil reabrió la tensión entre libertad de expresión, daño y deber de actuar.
- PL 2630/2020 expresa la discusión sobre transparencia, cuentas automatizadas, publicidad y moderación.
- Ley 15.211/2025: protección de niños y adolescentes en ambientes digitales, relevante para redes, juegos y diseño adictivo.

Nube de Gobierno: datos públicos e independencia operativa

Soberanía digital como capacidad de decidir, operar, auditar y proteger infraestructura crítica

- La Nube de Gobierno busca alojar y procesar datos públicos bajo jurisdicción brasileña y conforme a LGPD y LAI.
- Serpro y Dataprev aportan operación pública, interoperabilidad y control sobre datos de salud, educación y seguridad social.
- La soberanía no es solo localización territorial: requiere capacidades técnicas, portabilidad, auditoría y continuidad.
- Para universidades públicas, el caso permite discutir contratación de nube, datos sensibles, dependencia de proveedores y gobernanza.


Actividad: mapa regulatorio del caso Brasil

Comparar el modelo brasileño con UE, EE.UU., China y Argentina

- Clasificar cada instrumento: hard law, soft law, jurisprudencia, política pública o infraestructura estratégica.
- Identificar riesgos: datos personales, moderación, menores, dark patterns, IA, plataformas y soberanía operativa.
- Relacionar principios éticos con evidencias: evaluación de impacto, transparencia, auditoría y canales de reclamo.
- Producto esperado: matriz breve que explique qué controles exigiría una universidad pública antes de contratar IA en nube.

Operacionalizar soft law en un proyecto de IA

Secuencia para transformar instrumentos en controles verificables



3

Declaraciones político-diplomáticas y cooperación

Consensos internacionales que orientan agendas, capacidades y convergencia

Qué son y por qué importan

No imponen obligaciones jurídicas directas, pero ordenan la agenda global

- Consolidan consensos políticos y prioridades de cooperación internacional.
- Promueven redes, capacidades, investigación, buenas prácticas y participación multiactor.
- Orientan convergencia regulatoria y ayudan a interpretar hacia dónde se mueve la gobernanza global.
- En esta categoría conviene ubicar Paris 2025, Singapore Consensus, ASEAN AI SAFE y New Delhi 2026.

Declaración de París 2025

Statement on Inclusive and Sustainable AI for People and the Planet

- AI Action Summit, París, 10–11 de febrero de 2025, con participación de gobiernos, sociedad civil, sector privado, academia e investigación.
- Prioriza acceso a IA, reducción de brechas digitales, apertura, inclusión, transparencia, ética, seguridad y confianza.
- Incluye sostenibilidad ambiental, futuro del trabajo, cooperación internacional y gobernanza multiactor.
- Es una declaración político-diplomática: orienta agendas y cooperación, no opera como norma vinculante.

Paris Charter on AI in the Public Interest

Una segunda pieza de París: IA orientada al interés público

- Plantea que el desarrollo, despliegue y gobernanza de la IA deben servir al interés público.
- Destaca apertura, rendición de cuentas, participación y transparencia.
- Enfatiza infraestructura, bienes públicos digitales, datos de calidad, auditoría independiente y sostenibilidad.
- Útil para conectar ética de IA con políticas públicas, soberanía tecnológica y universidad pública.

Singapore Consensus 2025

Prioridades globales de investigación en seguridad de IA

- Documento surgido de SCAI 2025, publicado por una agencia del Gobierno de Singapur el 8 de mayo de 2025.
- Busca identificar y priorizar áreas técnicas de investigación en seguridad de IA con amplio consenso científico.
- Construye sobre el International AI Safety Report presidido por Yoshua Bengio.
- Sirve como documento vivo para conversaciones entre policymakers, científicos, industria y público.

Fuente: Singapore Conference on AI, "The Singapore Consensus on Global AI Safety Research Priorities", 08/05/2025.

Singapore Consensus: lectura técnica

Aporta una agenda de investigación, no una ley

Tres tipos de desafíos

- Development: crear sistemas confiables, robustos y seguros.
- Assessment: evaluar riesgos antes y durante el despliegue.
- Control: monitorear, intervenir y corregir después del despliegue.

Uso docente y de investigación

- Definir líneas de tesis y proyectos aplicados.
- Relacionar safety con evaluación, red-teaming y monitoreo.
- Detectar brechas: agentes, multimodalidad, ciberseguridad y gobernanza.

ASEAN AI SAFE

Red regional para seguridad de IA en el Sudeste Asiático

- Declaration on the Establishment of an ASEAN AI Safety Network.
- El DOCX la ubica correctamente como declaración político-institucional de cooperación regional.
- Su foco es fortalecer capacidades, coordinar esfuerzos, investigación y buenas prácticas en seguridad de IA.
- Relevancia: muestra cómo una región puede crear infraestructura de cooperación sin una ley única vinculante.

AI Impact Summit Declaration, New Delhi 2026

Cooperación global, impacto social y uso confiable de IA

- Declaración de la AI Impact Summit, Nueva Delhi, 18–19 de febrero de 2026, publicada por el Ministerio de Asuntos Exteriores de India.
- El DOCX la clasifica como declaración político-diplomática internacional.
- Se orienta a cooperación global, impacto social, desarrollo, inclusión y uso confiable de la IA.
- Completa la secuencia internacional: Bletchley/Seoul, París, Singapur y Nueva Delhi.

Comparación de declaraciones y consensos recientes

Diferenciar alcance político, técnico y regional

Instrumento	Foco	Función	Uso en clase/proyecto
París 2025	IA inclusiva, sostenible y confiable	Consenso político multiactor	Agenda pública, brechas, sostenibilidad y derechos
Paris Charter	IA en interés público	Principios para bienes públicos y participación	Universidad, políticas públicas y soberanía tecnológica
Singapore 2025	Investigación técnica en seguridad de IA	Priorizar dominios de safety	Tesinas, evaluación, monitoreo y control
ASEAN AI SAFE	Red regional de seguridad	Cooperación y capacidades	Modelo institucional de cooperación regional
New Delhi 2026	Impacto social y uso confiable	Cooperación global e inclusión	IA para desarrollo, Global South y políticas públicas

Fuentes: Élysée; SCAI Singapore; ASEAN; MEA India; DOCX del usuario.



4

Herramientas, riesgos y evidencia

Conectar ética, regulación y práctica de ingeniería

Herramientas de IA responsable

Kits que ayudan a pasar de principios a evidencia

AI Fairness 360

Toolkit abierto para examinar, reportar y mitigar discriminación y sesgos durante el ciclo de vida de modelos de ML.

Fairlearn

Paquete Python para evaluar y mitigar desigualdades de desempeño entre grupos, con métricas y visualizaciones.

VerifyML

Gobernanza mediante model cards, documentación, requisitos de equidad, pruebas y reportes para equipos de datos y cumplimiento.

Bases de datos y repositorios de riesgos

Casos reales y taxonomías para analizar daños

AI Incident Database

- Eventos de daño o casi-daño con sistemas de IA implicados.
- Útil para estudiar causa raíz, responsabilidades y controles.
- Conecta ética con gestión de incidentes y seguridad.

MIT AI Risk Repository

- Riesgos extraídos de múltiples marcos y clasificaciones.
- Taxonomías por dominio y por causalidad.
- Sirve para matrices de riesgo y evaluación de impacto.

AI Fairness 360: ejemplo de uso

Auditar y mitigar sesgos en modelos de clasificación o scoring

Caso

Selección de becas, admisión, crédito o priorización de servicios.

Se compara desempeño por grupo protegido: género, edad, zona, discapacidad u otra variable pertinente.

Flujo técnico

1. Definir grupos privilegiados / no privilegiados.
2. Medir disparidad: statistical parity, disparate impact, equal opportunity.
3. Aplicar mitigación pre, in o post-procesamiento.
4. Reentrenar y documentar trade-offs.

Evidencia

Reporte de métricas antes / después.

Justificación de umbrales aceptables.

Registro de datos usados, límites del modelo y decisión humana de aprobación.

Fairlearn: ejemplo de uso

Comparar desempeño por grupos y reducir desigualdades de error

Caso

Modelo que recomienda entrevistas laborales, asigna riesgo académico o clasifica reclamos.

La precisión global parece buena, pero un grupo recibe más falsos negativos o falsos positivos.

Flujo técnico

1. Crear MetricFrame con métrica global y por grupo.
2. Revisar selection rate, FPR, FNR, accuracy o MAE por grupo.
3. Usar mitigadores como ExponentiatedGradient o ThresholdOptimizer.
4. Comparar calidad vs equidad.

Evidencia

Dashboard o tabla por grupo.

Registro del criterio de fairness elegido.

Informe de impacto y decisión de despliegue con supervisión humana.

VerifyML: ejemplo de uso

Documentar modelos, tests y criterios de aceptación antes del despliegue

Caso

Un equipo quiere publicar un modelo de scoring o recomendación con aprobación de negocio, compliance y datos.

La pregunta no es solo si el modelo predice, sino si está documentado y testeado.

Flujo técnico

1. Crear una model card con finalidad, datos, usuarios, límites y métricas.
2. Ejecutar tests de performance, explicabilidad y fairness.
3. Definir umbrales “pasa / no pasa”.
4. Generar reporte legible para gestión.

Evidencia

Model card versionada.

Resultados automáticos de tests.

Responsables, observaciones, riesgos residuales y condiciones de uso.

AI Incident Database: envergadura y utilidad

Aprender de incidentes reales para anticipar riesgos en proyectos

Qué registra

Daños o casi-daños reales asociados al despliegue de sistemas de IA.

Funciona como memoria colectiva de fallas, impactos y señales tempranas.

Tamaño

MIT AI Incident Tracker clasifica más de 1.400 reportes reales provenientes de AIID.

Partnership on AI ya describía la base como compuesta por más de 1.200 reportes.

Cómo usarla

Buscar casos por dominio, daño, severidad o tipo de sistema.

Extraer lecciones: datos, supervisión, límites, monitoreo e incident response.

AI Incident Database: ejemplos para clase

Casos que muestran que el riesgo de IA no es solo teórico

Ejemplos recientes

Salud: sistema TruDi Navigation con IA fue señalado en reportes por posible contribución a un ACV durante una sinuplastia.

Agentes de IA: un agente en contexto corporativo produjo una instrucción que derivó en exposición interna de datos sensibles.

Desarrollo de software: un agente de codificación con permisos excesivos eliminó una base de producción y backups, con impacto operativo.

Lectura ética y de gobernanza

Los incidentes permiten discutir causa raíz, cadena de responsabilidades y controles fallidos.

Ayudan a transformar ética en procedimientos: permisos mínimos, pruebas, rollback, monitoreo y revisión humana.

También evidencian sesgos de reporte: no todo incidente se publica y la calidad de los datos varía.

MIT AI Risk Repository: cómo funciona y tamaño actual

Base estructurada para construir matrices de riesgo y evaluación de impacto

Estructura

Combina una base de riesgos extraídos de marcos publicados con dos taxonomías:

- causal: cómo, cuándo y por qué ocurre el riesgo;
- dominio: qué tipo de daño o área afecta.

Tamaño

Versión 4, diciembre de 2025:

- 65 marcos publicados;
- más de 1.600 riesgos extraídos;
- más de 1.700 riesgos / categorías codificadas;
- 7 dominios y 24 subdominios.

Uso práctico

Seleccionar riesgos relevantes para el caso.

Mapear causas, actores, etapa del ciclo de vida y mitigaciones.

Cruzar con AI Act, NIST AI RMF, ISO y evidencias del proyecto.

MIT AI Risk Repository: agregados recientes

Ejemplos de marcos incorporados en actualizaciones 2025

Agregados destacados

Taxonomía de fallas de IA generativa basada en 499 incidentes reportados públicamente.

Discusión del gobierno del Reino Unido sobre capacidades y riesgos de IA frontera.

Marco de riesgos catastróficos: CBRN, ciberofensiva, pérdida de control, riesgo ambiental y geopolítico.

Nuevo subdominio sobre riesgos multiagente incorporado en 2025.

Cómo llevarlo a proyecto

Armar registro inicial de riesgos antes de entrenar o comprar una solución.

Elegir mitigaciones: evaluación de datos, red teaming, supervisión humana, límites de autonomía y monitoreo.

Actualizar la matriz cuando cambian modelo, datos, proveedores, contexto o regulación.

Riesgos de IA que deben cruzarse con marcos regulatorios

Una matriz mínima para proyectos de IA

- Sesgo y equidad: discriminación, asignación injusta o peor calidad de servicio para algunos grupos.
- Privacidad y fuga de datos: exposición, extracción o uso no autorizado de información personal.
- Robustez y confiabilidad: alucinaciones, errores, degradación por data drift y fallas de monitoreo.
- Mal uso y ciberseguridad: prompt injection, ataques multimodales, deepfakes, model attacks y cadena de suministro.

NIST: explicabilidad y sesgo

La explicación no reemplaza el control de daños

XAI

- Explicación: razones junto al resultado.
- Significatividad: comprensible para el usuario.
- Exactitud: reflejar el proceso real.
- Límites del conocimiento: reconocer incertidumbre y contexto.

Sesgo

- El sesgo puede surgir en datos, diseño, objetivos y despliegue.
- No basta con precisión global: se requieren métricas por grupos.
- La mitigación exige documentación, gobernanza y revisión continua.

Shadow AI, dependencia cognitiva y ataques multimodales

Riesgos actuales para organizaciones educativas y públicas

- Shadow AI: uso de herramientas no aprobadas para tratar información institucional o personal.
- Dependencia cognitiva: delegación excesiva de juicio, escritura, evaluación o programación en IA.
- Ataques multimodales: combinación de texto, imagen, audio o video para manipular sistemas de IA.
- Riesgo regulatorio: multas, litigios, pérdida de confianza y limitaciones para operar.

Fuente: presentación original del usuario; actualización de enfoque 2026.


5

Aplicación docente e institucional

Cómo usar la clasificación en cursos, tesinas y proyectos de IA

Del instrumento a la actividad evaluable

Secuencia para transformar instrumentos en controles verificables



Actividad 1: mapa regulatorio de un caso de IA

Para estudiantes de informática o gestión de proyectos

- Elegir un caso: selección de CV, chatbot académico, detección de fraude, recomendador educativo o agente de soporte.
- Clasificar los instrumentos aplicables en hard law, soft law y declaraciones/cooperación.
- Identificar riesgos: datos, sesgo, explicación, seguridad, derechos y responsabilidad.
- Proponer controles: métricas, documentación, supervisión humana, auditoría e incident response.

Actividad 2: comparar París, Singapur y Nueva Delhi

Para discutir gobernanza global de IA

- París: ¿cómo vincula inclusión, sostenibilidad, derechos y cooperación internacional?
- Singapur: ¿qué prioridades técnicas de safety pueden transformarse en líneas de investigación?
- Nueva Delhi: ¿cómo aparece el eje de impacto social, desarrollo y Global South?
- Resultado esperado: una matriz de convergencias, diferencias y aplicaciones para una universidad pública.

Checklist final para evaluar un proyecto de IA responsable

Síntesis para cierre de clase o revisión institucional

- ¿Cuál es la finalidad legítima y qué problema público o social resuelve?
- ¿Qué obligaciones de hard law se activan por datos, riesgo, derechos o contexto?
- ¿Qué soft law se usará para medir confianza, equidad, seguridad y gobernanza?
- ¿Qué evidencia queda documentada para auditoría, reclamos, incidentes y mejora continua?
- ¿Qué agenda internacional ayuda a justificar cooperación, investigación o política pública?



Cierre

Una lectura integrada

La IA responsable combina cumplimiento, gestión de riesgos y cooperación internacional

Mensaje central

La clasificación del DOCX mejora la arquitectura conceptual de la PPTX

- Hard law responde: “qué obligaciones debemos cumplir”.
- Soft law responde: “cómo diseñamos, medimos y documentamos IA confiable”.
- Declaraciones y cooperación responden: “qué agenda internacional orienta capacidades, investigación y políticas públicas”.
- Para informática, el desafío es traducir todo esto en controles técnicos, evidencia, trazabilidad y decisiones responsables.

Fuentes principales incorporadas

Referencias para actualizar y sostener la presentación

DOCX del usuario: “Clasificación de los instrumentos sobre IA y ética”.

Élysée: AI Action Summit 2025; Singapore Conference on AI; ASEAN; MEA India.

Comisión Europea, Consejo de Europa, NIST, UNESCO, OECD, ISO/IEC, EDPB, FTC, EEOC y OMB.

Estados Unidos 2026: Executive Order “Promoting Advanced Artificial Intelligence Innovation and Security”.

AI Fairness 360 / LF AI & Data; Fairlearn; VerifyML documentation.

AI Incident Database; MIT AI Incident Tracker; MIT AI Risk Repository V4 update (Dec. 2025).

Reuters, The Guardian y Business Insider: ejemplos recientes de incidentes de IA.

Brasil: Marco Civil de Internet, LGPD/ANPD, STF Tema 987, PL 2630/2020, Ley 15.211/2025 y Nube de Gobierno.

Estados Unidos 2026: Executive Order “Promoting Advanced Artificial Intelligence Innovation and Security” (White House, 02/06/2026); AP News; WSJ.

Magnifica Humanitas: aporte ético-humanista

Tres claves para integrar la encíclica en el mapa de frameworks y regulaciones de IA

Naturaleza

No es hard law ni estándar técnico: funciona como referencia ético-social para el discernimiento institucional.

Aporte específico

Reubica la IA en una tradición de dignidad humana, bien común, verdad, trabajo, justicia social y paz.

Uso en la PPTX

Complementa AI Act, GDPR, UNESCO, OECD, NIST e ISO con una lectura de impactos humanos y sociales.

Idea fuerza: la IA debe evaluarse desde el primado de la persona, no solo desde eficiencia, innovación o competitividad.

Fuente de referencia: Santa Sede, Magnifica Humanitas; lectura integrada con la clasificación de instrumentos sobre IA y ética.

Principios y riesgos para evaluar proyectos de IA

De los valores a preguntas operativas de gobernanza

Principios aplicables

Dignidad humana, bien común, subsidiariedad, solidaridad, justicia social, cuidado de la casa común y paz.

Criterio central

La persona no debe reducirse a dato, perfil, recurso productivo o variable de optimización.

-  **Riesgos** Concentración de poder, desinformación, precarización del trabajo, automatización irresponsable y usos bélicos o manipulativos.
-  **Controles** Supervisión humana, transparencia, evaluación de impacto, métricas de equidad, protección de datos y rendición de cuentas.
-  **Pregunta guía** ¿Esta IA amplía capacidades humanas y vínculos sociales, o desplaza juicio, responsabilidad y participación?

Puentes con frameworks y uso docente

Cómo convertir la encíclica en una matriz de análisis para clase o proyectos institucionales

AI Act / GDPR

Derechos fundamentales, protección de datos, supervisión humana y obligaciones para sistemas de alto riesgo.

UNESCO / OECD

Dignidad, derechos humanos, inclusión, desarrollo sostenible, confianza y cooperación internacional.

NIST / ISO

Gobernanza, medición de riesgos, trazabilidad, roles, controles y mejora continua.

Actividad sugerida

Elegir un caso de IA y cruzarlo con dignidad, bien común, trabajo, verdad, inclusión, paz y protección de datos.

Producto esperado

Ficha breve con riesgos, marcos aplicables, controles y decisión argumentada de despliegue responsable.

Clave pedagógica: Magnifica Humanitas opera como una capa de sentido ético-humanista que ayuda a interpretar instrumentos jurídicos y técnicos.