

De los frameworks a la praxis ética

Cómo evaluar, auditar y documentar sistemas de IA en proyectos informáticos

Clase integradora · Módulo de Ética



La clase redondea la formación: convierte marcos normativos y éticos en una metodología de actuación profesional.

1 Leer

Identificar normas, principios y obligaciones

2 Evaluar

Analizar finalidad, datos, riesgos e impactos

3 Controlar

Diseñar medidas técnicas, humanas y organizacionales

4 Decidir

Autorizar, pilotear, suspender o reformular

Resultado esperado Que cada estudiante pueda producir un dictamen ético-técnico defendible, con evidencia y criterios de no-go.

Los marcos no son un “anexo legal”: son entradas para el diseño, la documentación y la decisión.

Hard law	AI Act, GDPR, leyes de datos, normas sectoriales	Cumplimiento, derechos, contratos, auditoría legal
Soft law	NIST AI RMF, ISO/IEC 42001, UNESCO, OECD, ALTAI	Gestión de riesgos, controles, métricas y evidencia
Declaraciones	París, Singapur, ASEAN, Nueva Delhi	Agenda pública, capacidades, cooperación y sostenibilidad



Método transversal: ciclo de ocho etapas



No es una lista de chequeo decorativa: cada etapa debe dejar evidencia y responsable.

La pregunta clave: ¿cómo demostramos que actuamos con diligencia profesional?

Ficha de finalidad

problema, usuarios, límites de uso

Mapa de actores

afectados, decisores, operadores y canales de reclamo

Mapa de datos

origen, calidad, permisos, retención y seguridad

Registro de riesgos

daños previsibles, controles y riesgo residual

Model card / datasheet

métricas, limitaciones, usos prohibidos y trazabilidad

Dictamen

desplegar, pilotear, reformular, suspender o no autorizar

La ética aplicada se vuelve auditable cuando genera trazabilidad, no solo intenciones.

¿Puede evaluarse si un sistema es ético?

Sí, pero con una advertencia: la rúbrica no reemplaza el juicio profesional.

- | | | |
|---|-----------------------------------|-------------------------------------|
| 1 | Estructura la deliberación | ordena criterios y evita omisiones |
| 2 | Exige evidencia | no acepta afirmaciones sin prueba |
| 3 | Expone riesgos residuales | muestra qué queda sin resolver |
| 4 | Conecta puntaje y decisión | no todo se compensa con un promedio |

Un sistema puede puntuar alto y aun así ser no autorizable si activa un criterio crítico de veto.

Escala de evaluación: 0 a 3

0	Crítico	1	Inicial	2	Adecuado	3	Avanzado
No fue considerado o existe vulneración grave		Hay declaraciones, pero faltan controles o evidencia		Controles implementados con evidencia suficiente		Auditoría, monitoreo y mejora continua	

Interpretación orientativa

30–36	Aprobado con monitoreo	24–29	Aprobado con condiciones	18–23	Piloto restringido y reversible	< 18	Reformular o no autorizar
--------------	------------------------	--------------	--------------------------	--------------	---------------------------------	----------------	---------------------------

El puntaje informa; la responsabilidad decide.

Para cada dimensión: formular la pregunta, pedir evidencia y asignar nivel 0–3.

Dimensión	Pregunta central	Evidencia esperada
1 Finalidad y necesidad	¿El problema es legítimo y la IA es necesaria?	Ficha de finalidad, alternativas y usos prohibidos
2 Derechos y cumplimiento	¿Respetar normas, derechos y códigos profesionales?	Matriz normativa y evaluación de impacto
3 Privacidad y datos	¿Los datos son pertinentes, mínimos y seguros?	Mapa de datos, base legal, retención y accesos
4 Transparencia	¿Se comunica cuándo interviene IA y con qué límites?	Model card, explicación y documentación pública

Para cada dimensión: formular la pregunta, pedir evidencia y asignar nivel 0–3.

Dimensión	Pregunta central	Evidencia esperada
5 Equidad	¿Errores y beneficios se distribuyen injustamente?	Métricas por grupo, proxies y mitigación
6 Robustez y seguridad	¿Resiste fallas, ataques y cambios de contexto?	Pruebas, red teaming y plan de incidentes
7 Explicabilidad	¿La decisión puede ser comprendida y revisada?	Explicaciones, variables relevantes y límites
8 Supervisión humana	¿Una persona puede rechazar, escalar o detener?	Procedimiento, roles y tiempo real de revisión

Para cada dimensión: formular la pregunta, pedir evidencia y asignar nivel 0–3.


	Dimensión	Pregunta central	Evidencia esperada
9	Responsabilidad	¿Quién decide, responde y acepta el riesgo residual?	RACI ética, registro de decisiones y logs
10	Participación y apelación	¿Las personas afectadas pueden reclamar y corregir?	Canal de reclamo, apelación y plazos
11	Impacto laboral/social	¿Afecta autonomía, competencias o inclusión?	Consulta, capacitación e indicadores laborales
12	Monitoreo y reversibilidad	¿Puede detectarse deriva, corregir o retirar?	Indicadores, rollback y plan de salida

Algunas condiciones no pueden compensarse con un buen promedio.

- | | |
|---|---|
| ! Finalidad ilegal, ilegítima o desproporcionada | ! Riesgo crítico de seguridad o daño irreversible |
| ! Sin base válida para datos personales o sensibles | ! Proveedor impide auditoría de decisiones que afectan derechos |
| ! Discriminación grave no mitigada | ! Nadie tiene autoridad efectiva para detener el sistema |
| ! Decisión de alto impacto sin apelación | ! Uso fuera de la finalidad aprobada |

Dictamen automático ante veto: suspender, reformular o no autorizar hasta resolver la condición crítica.

Auditar equidad implica definir el daño, medirlo, mitigar y justificar el riesgo residual.



Métricas orientativas según el daño

Falsos positivos	crítico en vigilancia, fraude, disciplina
Falsos negativos	crítico en salud, becas, protección social
Tasa de selección	compara oportunidades o resultados favorables
Calibración	evalúa si el puntaje significa lo mismo por grupo

El objetivo no es “usar una herramienta”, sino generar pruebas reproducibles que alimenten el dictamen.

AI Fairness 360

métricas y mitigación de sesgos en ML

antes / durante / después

VerifyML

model cards, pruebas y umbrales

gobernanza y aceptación

Fairlearn

métricas por grupo y mitigadores

MetricFrame y trade-offs

Hoja de cálculo

tasas, matrices y comparación

actividad conceptual sin código

Evidencia mínima: tabla antes/después, definición de fairness elegida, trade-offs y decisión de despliegue.

La auditabilidad define qué evidencia podemos exigir antes de desplegar un sistema de IA.

Caja negra

se observan entradas,
salidas y conducta

Caja gris

hay acceso parcial a
documentación, logs o API

Caja blanca

se revisan datos, código,
pipeline, modelo y
decisiones

La caja negra detecta el comportamiento; la caja blanca ayuda a explicar las causas; la caja gris es la situación contractual más frecuente.

Qué puede demostrar cada enfoque de auditoría

No son alternativas excluyentes: una auditoría robusta combina conducta externa, evidencia técnica v controles institucionales.

Aspecto	Caja negra	Caja gris	Caja blanca
Acceso	Entradas y salidas	Documentación parcial, API, logs	Datos, código, pipeline y decisiones
Pregunta	¿Qué hace?	¿Qué hace y qué evidencia lo explica?	¿Cómo fue construido y por qué responde así?
Fortaleza	Independencia y prueba conductual	Factibilidad en proveedores	Diagnóstico profundo y trazabilidad
Limitación	Difícil identificar causas	Evidencia incompleta	Puede perder independencia externa
Uso típico	Plataformas externas	APIs y contratos comerciales	Sistemas propios o plenamente auditables

Regla didáctica: para alto impacto, la opacidad debe reducirse o compensarse con auditoría independiente, límites y monitoreo.

LLM: plataformas, pesos y modelos abiertos

El modelo de provisión cambia la evidencia disponible: “descargable” u “open source” no significa automáticamente caja blanca.

Plataforma comercial · **Caja negra predominante**

pruebas de prompts, privacidad, contrato, retención, cambios de versión

API comercial · **Negra / gris**

logs, SLA, seguridad, red teaming, cláusulas de auditoría y salida

Pesos abiertos · **Caja gris técnica**

se ejecuta localmente, pero puede faltar dataset, filtrado y alineamiento

Modelo abierto documentado · **Blanca / gris**

pesos, código, licencia, model card, evaluaciones y pipeline reproducible

En universidades y organismos públicos conviene separar control de infraestructura, control de datos y control del modelo.

Más control técnico implica también más responsabilidad institucional sobre configuración, fine-tuning, seguridad e incidentes.

La auditabilidad no depende solo de si el modelo es abierto o cerrado, sino de cuánto se conoce y controla del sistema completo.

Arquitecturas híbridas: varias cajas

En una solución con RAG, herramientas o bases internas, la opacidad del LLM no vuelve opaco a todo el sistema.



Bajo control institucional

- documentos
- prompts
- reglas de recuperación
- control de acceso y logs

Acceso parcial

- API, contrato y seguridad
- evaluaciones del proveedor
- logs disponibles y cambios de versión

Componentes críticos

- herramientas que ejecutan acciones
- datos sensibles
- rollback y autorización humana

Antes de aprobar, el dictamen debe decir qué parte es negra, gris o blanca y qué riesgo queda sin auditar.

Cuando la IA puede ejecutar acciones, la auditoría deja de mirar solo respuestas y debe mirar consecuencias.

1. Modelo • sesgos, alucinaciones, robustez, toxicidad, límites de conocimiento

2. Sistema • prompts, memoria, RAG, herramientas, identidad, permisos y orquestación

3. Acciones • qué ejecutó, con qué autorización, sobre qué datos, si fue reversible y quién responde

Alertas críticas en agentes

acciones sin logs completos
credenciales o privilegios excesivos
delegación a otros agentes sin trazabilidad
ausencia de rollback o kill switch
confusión entre recomendación y autorización

Cuanto mayor es la autonomía operativa, menor debe ser la tolerancia a la opacidad.

La profundidad de auditoría requerida debe crecer con el impacto, la autonomía y la irreversibilidad de las acciones.

Autonomía	Ejemplo	Auditoría mínima	Dictamen orientativo
Baja	borradores, resúmenes	caja negra controlada + política de uso	aprobable con monitoreo
Media	RAG con documentos internos	caja gris + logs + control de acceso	piloto o aprobado con condiciones
Alta	agente que modifica datos o envía mensajes	caja blanca en componentes críticos + permisos mínimos	condicionado y reversible
Crítica	infraestructura, derechos, datos sensibles	auditoría independiente + supervisión humana obligatoria	no autorizar sin evidencia fuerte

Para sistemas de alto impacto, la imposibilidad de una auditoría de caja gris como mínimo debe ser una alerta crítica.

Caso práctico 1: sistema de priorización de becas

Un modelo ordena postulantes según probabilidad de continuidad académica. Una variable de conexión al campus funciona como proxy de conectividad y zona.

- 1 ¿Qué decisión puede apoyar y cuál no debería tomar?
- 2 ¿Qué error es más grave: falso positivo o falso negativo?
- 3 ¿Qué variables son proxies de desigualdad?
- 4 ¿Qué definición de equidad se prioriza?
- 5 ¿El sistema se despliega, se limita o queda como piloto?

Producto del grupo

Ficha del sistema

Mapa de actores

Métricas por grupo

Model card

Dictamen

Decisión final: desplegar, pilotear, reformular, suspender o no utilizar.

Proyectos complejos: responsabilidades fragmentadas

El riesgo suele emerger de la combinación de contratos, datos, arquitectura, incentivos y omisiones.




Pregunta práctica: ¿quién tiene autoridad real para aceptar el riesgo o detener el sistema?

La RACI ética asigna responsabilidad sobre decisiones críticas, no solo sobre tareas.

Responsible	Accountable	Consulted	Informed
Ejecuta	Responde	Aporta juicio	Debe saber
Autorizar uso de datos	jurídico, datos y titulares		
Aceptar riesgo residual	autoridad competente		
Suspender el sistema	responsable del servicio		
Comunicar incidente	seguridad + protección de datos		

Registro de decisiones: alternativa elegida, opciones descartadas, evidencia, objeciones y responsable.



La ética profesional no exige eliminar todo riesgo, sino identificarlo, justificarlo, reducirlo, monitorearlo y asumir responsabilidad.

No solo cambia cuántas tareas se hacen: cambia quién decide, quién aprende y quién responde.

Automatización

la tecnología ejecuta una tarea

Asistencia

la persona conserva la decisión

Reconfiguración

cambian roles, tiempos y saberes

Supervisión algorítmica

el sistema mide o asigna trabajo

Riesgos a evaluar

- Shadow AI y fuga de información
- Licencias, propiedad intelectual y confidencialidad
- Código vulnerable o no comprendido
- Deskilling y dependencia cognitiva
- Métricas de productividad que incentivan aceptación acrítica

“Humano en el loop” no basta si la persona no puede comprender, cuestionar o detener.



Comprende finalidad, límites y errores frecuentes



No es evaluado por confirmar rápido



Tiene información y tiempo para revisar



Posee autoridad para detener el proceso



Puede modificar, rechazar o escalar



Documenta la decisión final

En sistemas de alto impacto, la supervisión debe ser una capacidad institucional, no una carga individual aislada.

Cuando la evidencia es incompleta, la respuesta no es improvisar: es anticipar, limitar, pilotear y revisar.

Humanos aumentados

voluntariedad, acceso, dependencia, datos corporales

Biometría

vigilancia, falsos positivos, proporcionalidad y finalidad

Neurotecnología

privacidad mental, identidad, autonomía y consentimiento

Green IT / IA

energía, infraestructura, ciclo de vida y sostenibilidad

Ficha de anticipación: tecnología y madurez · promesa · incertidumbre · afectados · irreversibilidad · gobernanza · señales tempranas · decisión.

Cada grupo elige un caso y produce un dictamen ético-técnico de una página.

Chatbot académico

orientación estudiantil, privacidad y responsabilidad

Selección de CV

sesgo, explicación y apelación

Asistente de programación

seguridad, PI y deskilling

Sistema de becas

proxies socioeconómicos y falsos negativos

Agente de soporte

errores, escalamiento y datos sensibles

Entrega

Rúbrica aplicada + criterios críticos + decisión + condiciones de seguimiento.

1. Sistema y finalidad

qué problema resuelve, población y límites

2. Riesgos principales

datos, sesgos, seguridad, trabajo e impacto social

3. Rúbrica

puntajes 0–3 y justificación breve

4. Criterios de veto

si aparece alguno, qué debe corregirse

5. Controles

medidas técnicas, humanas y organizacionales

6. Decisión

aprobar, condicionar, pilotear, suspender o no autorizar

Idea de cierre

La ética profesional en informática es la capacidad de justificar decisiones técnicas con evidencia, responsabilidad y límites claros.